

Lista 1 - Séries Temporais

Table of contents

0.1	Questão 1	1
0.2	Questão 2	12
0.3	Questão 3	13
0.4	Questão 4	15
0.5	Questão 5	18
0.6	Questão 6	23

0.1 Questão 1

Considere os log retornos diários do IBOVESPA de 4/07/1994 a 19/08/2010:

```
data <- tq_get(
  "^BVSP",
  from = "1994-07-04",
  to = "2010-08-19",
  get = "stock.prices")


data <- data %>%
  select(-symbol) %>%
  mutate(date = as.Date(date, format = "%Y-%m-%d"))
```

- Faça um gráfico da série e da série dos log-retornos, calcule as estatísticas de média, mediana, variância, assimetria e curtose, e comente.

```
# gráfico da série temporal

ggplot(data, aes(x = date, y = adjusted)) +
  geom_line(color = "blue", size = 1) +
```

```
labs(
  title = "Série Temporal do IBOVESPA",
  x = "Data",
  y = "adjusted"
) +
theme_minimal() +
scale_x_date(date_labels = "%Y", date_breaks = "1 year")
```



```
# calculando log retorno diário


data <- data %>%
  arrange(date) %>%
  mutate(log_return = log(adjusted / lag(adjusted)))

# gráfico do log retorno
```

```

ggplot(data, aes(x = date, y = log_return)) +
  geom_line(color = "lightblue", size = 1) +
  labs(
    title = "Série Temporal do IBOVESPA (Log Retorno)",
    x = "Data",
    y = "Log Retorno do adjusted"
  ) +
  theme_minimal() +
  scale_x_date(date_labels = "%Y", date_breaks = "1 year")

```



```

stats <- data.frame(
  Estatística = c("Média", "Mediana", "Variância", "Assimetria", "Curtose"),
  Valor = c(
    mean(data$adjusted, na.rm = TRUE),
    median(data$adjusted, na.rm = TRUE),
    var(data$adjusted, na.rm = TRUE),

```

```

    skewness(data$adjusted, na.rm = TRUE),
    kurtosis(data$adjusted, na.rm = TRUE)
  )
)

kable(stats,
      caption = "Estatísticas descritivas do IBOVESPA",
      align = "c") %>%
kable_styling(bootstrap_options = c("striped"), full_width = FALSE)

```

Table 1: Estatísticas descritivas do IBOVESPA

Estatística	Valor
Média	2.414843e+04
Mediana	1.491200e+04
Variância	3.853972e+08
Assimetria	9.963455e-01
Curtose	-3.185480e-01


- Obtenha um histograma dos dados (série) e comente sobre a forma da distribuição, comparando com a distribuição Normal de mesma média e variância. Faça o QQ plot e comente.

```

#histograma

ggplot(data, aes(x = adjusted)) +
  geom_histogram(aes(y = after_stat(density)), bins = 30,
    fill = "skyblue", color = "black", alpha = 0.7) +
  stat_function(fun = dnorm, args = list(mean = mean(data$adjusted, na.rm = TRUE),
    sd = sd(data$adjusted, na.rm = TRUE)),
    color = "red", size = 1) +
  labs(title = "Histograma IBOVESPA com Comparação com a Distribuição Normal",
    x = "Preço Ajustado",
    y = "Densidade") +
  theme_minimal()


```



```
# qqplots
```

```
qqnorm(data$adjusted, main = "QQ Plot IBOVESPA - Comparação com a Normal")  
qqline(data$adjusted, col = "red")
```

QQ Plot IBOVESPA – Comparação com a Normal



Observa-se uma assimetria positiva, com uma cauda longa à direita. Isso é esperado, pois os preços financeiros geralmente não seguem uma distribuição normal. A curva em vermelho, representando uma distribuição normal ajustada, não modela bem os dados devido à assimetria e ao comportamento de cauda.

- Comente o significado da média e teste se a série é ruído branco ou não.

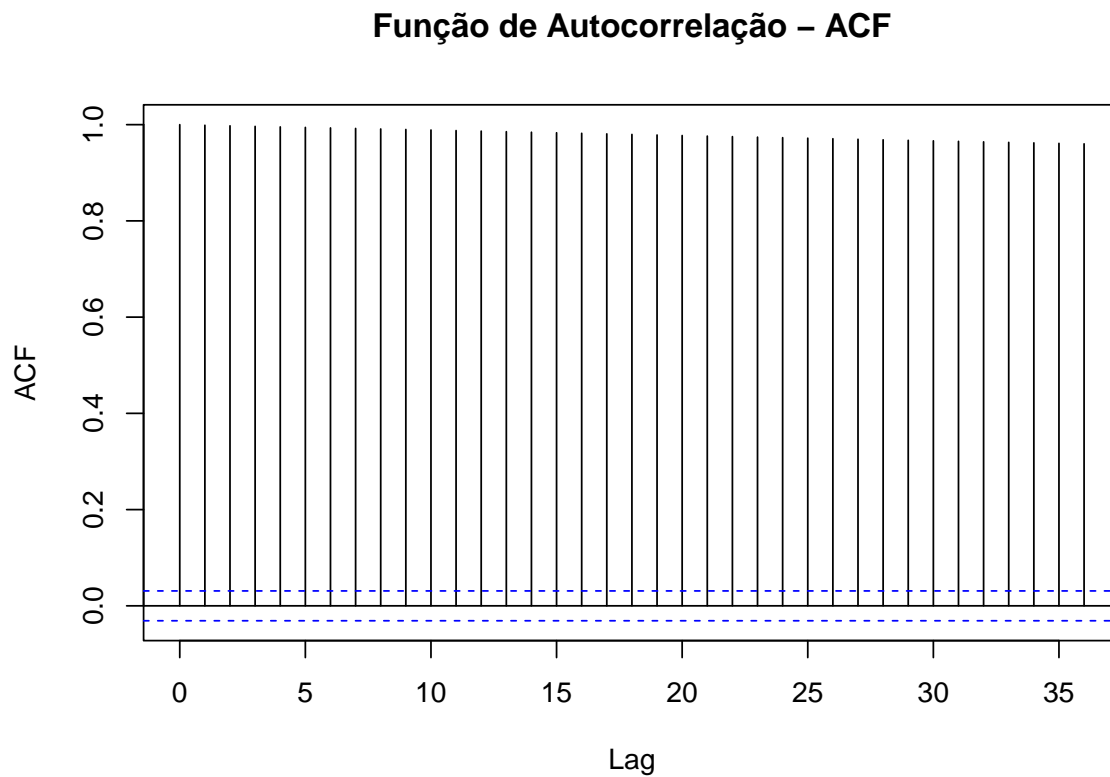
```
stats[1,]
```

	Estatística	Valor
1	Média	24148.43

Esta medida central pode ser interpretada como o comportamento típico ao longo do tempo.

```
# gráfico da função de autocorrelação  
  
adjusted <- na.omit(data$adjusted)
```

```
acf(adjusted, main = "Função de Autocorrelação - ACF")
```



```
# teste de Ljung-box
```

```
Box.test(adjusted, lag = 10, type = "Ljung-Box")
```

Box-Ljung test

```
data: adjusted
```

```
X-squared = 39497, df = 10, p-value < 2.2e-16
```

Observando o gráfico da função de autocorrelação há um forte indicativo da série não ser um ruído branco, aplicando o teste de Ljung-Box confirma-se que de fato não é o caso.

- Faz o item (b)-(c) para os log-retornos.

```
# medidas descritivas para log retorno

stats_logreturn <- data.frame(
  Mean = mean(data$log_return, na.rm = TRUE),
  Median = median(data$log_return, na.rm = TRUE),
  Variance = var(data$log_return, na.rm = TRUE),
  Skewness = skewness(data$log_return, na.rm = TRUE),
  Kurtosis = kurtosis(data$log_return, na.rm = TRUE)
)

kable(stats_logreturn,
  caption = "Estatísticas descritivas do Log Retorno diário do IBOVESPA",
  align = "c") %>%
  kable_styling(bootstrap_options = c("striped"), full_width = FALSE)
```

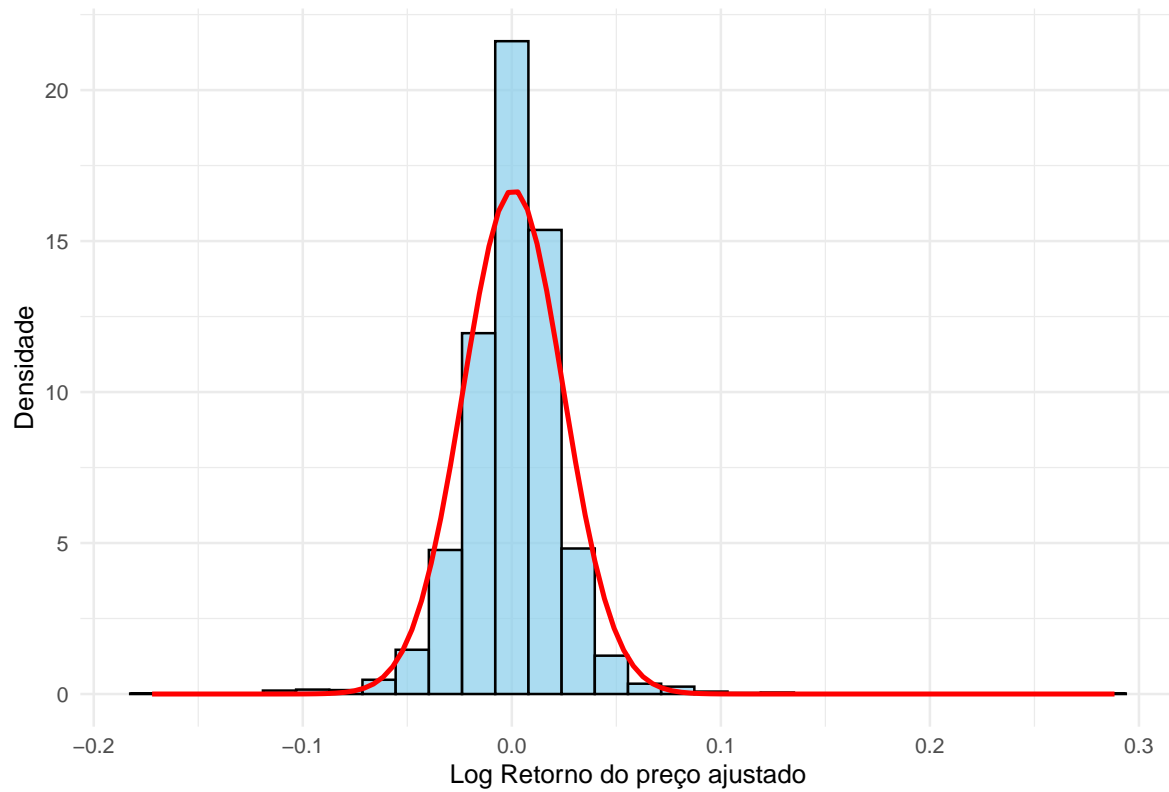
Table 2: Estatísticas descritivas do Log Retorno diário do IBOVESPA

Mean	Median	Variance	Skewness	Kurtosis
0.0007069	0.0013432	0.0005709	0.4509458	11.85277

```
# histograma para log retorno

ggplot(data, aes(x = log_return)) +
  geom_histogram(aes(y = after_stat(density)), bins = 30,
    fill = "skyblue", color = "black", alpha = 0.7) +
  stat_function(fun = dnorm, args = list(mean = mean(data$log_return, na.rm = TRUE),
    sd = sd(data$log_return, na.rm = TRUE)),
    color = "red", size = 1) +
  labs(title = "Histograma IBOVESPA com Comparação com a Distribuição Normal",
    x = "Log Retorno do preço ajustado",
    y = "Densidade") +
  theme_minimal()
```



Histograma IBOVESPA com Comparação com a Distribuição Normal



```
# qqplots log retorno
```


```
qqnorm(data$log_return, main = "QQ Plot IBOVESPA - Comparação com a Normal")  
qqline(data$log_return, col = "red")
```

QQ Plot IBOVESPA – Comparação com a Normal



```
# testando ruído branco  
  
log_return <- na.omit(data$log_return)  
  
acf(log_return, main = "Função de Autocorrelação - ACF")
```

Função de Autocorrelação – ACF



```
Box.test(log_return, lag = 10, type = "Ljung-Box")
```

Box-Ljung test

```
data: log_return  
X-squared = 69.061, df = 10, p-value = 6.729e-11
```

No gráfico de histograma do log retorno do preço ajustado há indícios de que os dados aderem a normalidade após a transformação. De forma similar, observa-se que o qqplot também tem um comportamento normal.

Observando o gráfico da função de autocorrelação, indica a possibilidade da série ser um ruído branco, mas aplicando o teste de Ljung-Box essa hipótese é rejeitada. O que indica que apesar de ter autocorrelação baixa, não é igual a zero.

0.2 Questão 2

Para os dados da série log-retornos mensais do SP500 de Junho/1994 a Agosto /2001:

```
data <- tq_get("^GSPC",
               from = "1994-06-01",
               to = "2001-08-01",
               get = "stock.prices")

data <- data %>%
  select(-symbol) %>%
  mutate(date = as.Date(date, format = "%Y-%m-%d"))
```

- Qual é o retorno medio anual sobre o periodo dos dados?

```
n_anos <- as.numeric(difftime(max(data$date), min(data$date), units = "days")) / 365

valor_inicial <- first(data$adjusted)
valor_final <- last(data$adjusted)

retorno_medio_anual <- (valor_final / valor_inicial)^(1 / n_anos) - 1

retorno_medio_anual
```

[1] 0.145399

- Qual é o retorno simples médio anualizado?

```
data <- data %>%
  arrange(date) %>%
  mutate(retorno_diario = (adjusted / lag(adjusted)) - 1)

data <- data %>% filter(!is.na(retorno_diario))

media_retorno_diario <- mean(data$retorno_diario)

retorno_simples_anualizado <- media_retorno_diario * 252

retorno_simples_anualizado
```

[1] 0.1502934

- Se vc investir R/. 1.00 no ativo no final de Dezembro de 1994, qual é o valor do investimento ao final do Dezembro de 2001?

```
log_retornos_perodo <- data %>%
  filter(date >= as.Date("1994-12-31") & date <= as.Date("2001-08-31")) %>%
  pull(retorno_diario)

# Calcular log-retorno total
log_retorno_total <- sum(log_retornos_perodo)

# Converter para retorno acumulado
retorno_acumulado <- exp(log_retorno_total)

# Calcular valor final do investimento
valor_inicial <- 1 # Investimento inicial
valor_final <- valor_inicial * retorno_acumulado

valor_final
```

[1] 2.923327

0.3 Questão 3

Considere os logretornos diários da PETR4 de 03/01 a 27/12/2000

```
data <- tq_get("^GSPC",
  from = "2000-03-01",
  to = "2001-12-27",
  get = "stock.prices")

data <- data %>%
  select(-symbol) %>%
  mutate(date = as.Date(date, format = "%Y-%m-%d"))

data <- data %>%
  arrange(date) %>%
  mutate(
    retorno_simples = (adjusted / lag(adjusted)) - 1,
    log_retorno = log(adjusted / lag(adjusted))
  )
```

- Qual é o retorno simples do dia 1 para o dia 2? E do primeiro para o 7mo?

```
retorno_dia1_para_dia2 <- data$retorno_simples[2]
retorno_dia1_para_dia7 <- (data$adjusted[7] / data$adjusted[1]) - 1

retorno_dia1_para_dia2;retorno_dia1_para_dia7
```

[1] 0.001863462

[1] 0.01631392

- Quanto é o log retorno do dia 5 para o dia 6? E do 5 dia para o 10mo?

```
logretorno_dia5_para_dia6 <- log(data$adjusted[6] / data$adjusted[5])
logretorno_dia5_para_dia10 <- log(data$adjusted[10] / data$adjusted[5])

logretorno_dia5_para_dia6; logretorno_dia5_para_dia10
```


[1] 0.008140129

[1] 0.002600612

- Calcule a função de autocorrelação estimada e comente.

```
logretornos <- na.omit(data$log_retorno)
acf_logretornos <- acf(logretornos,
                        main = "Função de Autocorrelação dos Logretornos do PETR4")
```

Função de Autocorrelação dos Logretornos do PETR4



```
acf_logretornos
```

Autocorrelations of series 'logretornos', by lag

0	1	2	3	4	5	6	7	8	9	10
1.000	0.017	-0.104	0.002	0.063	-0.053	-0.049	0.020	-0.050	0.014	-0.006
11	12	13	14	15	16	17	18	19	20	21
-0.051	0.103	0.092	-0.077	-0.007	0.002	0.026	-0.098	-0.045	0.001	-0.084
22	23	24	25	26						
0.023	0.059	0.047	-0.031	0.023						

0.4 Questão 4

- Quetão 21

A função $\gamma(\tau) = \sin(\tau)$ é uma possível função de autocovariância. Verifique sua resposta.

A função $\gamma(\tau)$ deve satisfazer as seguintes propriedades:

1. $\gamma(0) > 0$
2. $\gamma(-\tau) = \gamma(\tau)$
3. $|\gamma(\tau)| \leq \gamma(0)$
4. $\gamma(\tau)$ é não negativa definida, no sentido de que:

$$\sum_{j=1}^n \sum_{k=1}^n a_j a_k \gamma(\tau_j - \tau_k) \geq 0$$

para quaisquer números reais a_1, a_2, \dots, a_n e $\tau_1, \dots, \tau_n \in \mathbb{R}$.

É necessário verificar se $\gamma(\tau) = \sin(\tau)$ atende essas propriedades.

Verificando as propriedades para $\gamma(\tau) = \sin(\tau)$:

(i) Verificação de $\gamma(0) > 0$:

$$\gamma(0) = \sin(0) = 0,$$

logo, temos que $\gamma(0) = 0$, o que não é maior que zero. Portanto, a função não satisfaz a condição de ser não negativa em $\tau = 0$.

(ii) Verificação da simetria de $\gamma(\tau)$:

$$\gamma(-\tau) = \sin(-\tau) = -\sin(\tau),$$

logo, $\gamma(-\tau) \neq \gamma(\tau)$. Portanto, a função não é simétrica.

(iii) Verificação de $|\gamma(\tau)| \leq \gamma(0)$:

Para $\tau = \pi/2$ temos:

$$\gamma\left(\frac{\pi}{2}\right) = \sin\left(\frac{\pi}{2}\right) = 1, \quad \gamma(0) = \sin(0) = 0.$$

Logo, temos que $|\gamma(\tau)| = 1 \not\leq 0$. Portanto, a função não satisfaz a condição de ser limitada por $\gamma(0)$.

(iv) Verificação de não negatividade definida:

A condição de não negatividade definida exige que a soma

$$\sum_{j=1}^n \sum_{k=1}^n a_j a_k \gamma(\tau_j - \tau_k) \geq 0$$

para qualquer escolha de números reais a_1, a_2, \dots, a_n e τ_1, \dots, τ_n . No entanto, dado que $\gamma(\tau) = \sin(\tau)$ não é uma função simétrica e é oscilante, essa soma pode assumir valores negativos. Portanto, não podemos garantir que a função seja não negativa definida.

• Questão 25

Suponha que $\{X_t, t = 0, \pm 1, \dots\}$ seja uma sequência de variáveis aleatórias independentes, todas com a mesma distribuição, com $E\{X_t\} = \mu$, $\forall t$, e $\text{Var}\{X_t\} = \sigma^2$, $\forall t$.

Considere o processo $\{Y_t, t = 0, \pm 1, \dots\}$, onde: $Y_t = \frac{1}{2}X_t + \frac{1}{4}X_{t-1} + \frac{1}{8}X_{t-2}$.

O processo $\{Y_t\}$ é estacionário?

Cálculos do Processo $\{Y_t\}$

Calculando a esperança:

$$E[Y_t] = E\left(\frac{1}{2}X_t + \frac{1}{4}X_{t-1} + \frac{1}{8}X_{t-2}\right) = \frac{1}{2}E[X_t] + \frac{1}{4}E[X_{t-1}] + \frac{1}{8}E[X_{t-2}]$$

Como $E[X_t] = \mu$ para todos os t , temos:

$$E[Y_t] = \frac{1}{2}\mu + \frac{1}{4}\mu + \frac{1}{8}\mu = \left(\frac{1}{2} + \frac{1}{4} + \frac{1}{8}\right)\mu = \frac{7}{8}\mu.$$

Calculando a variância:

$$\text{Var}(Y_t) = \text{Var}\left(\frac{1}{2}X_t + \frac{1}{4}X_{t-1} + \frac{1}{8}X_{t-2}\right)$$

Utilizando a independência das variáveis X_t , temos:

$$\text{Var}(Y_t) = \left(\frac{1}{2}\right)^2 \text{Var}(X_t) + \left(\frac{1}{4}\right)^2 \text{Var}(X_{t-1}) + \left(\frac{1}{8}\right)^2 \text{Var}(X_{t-2})$$

Como $\text{Var}(X_t) = \sigma^2$, temos:

$$\text{Var}(Y_t) = \frac{1}{4}\sigma^2 + \frac{1}{16}\sigma^2 + \frac{1}{64}\sigma^2 = \left(\frac{1}{4} + \frac{1}{16} + \frac{1}{64}\right)\sigma^2 = \frac{21}{64}\sigma^2.$$

Calculando a covariância:

$$\text{Cov}(Y_t, Y_{t+s}) = E[Y_t Y_{t+s}] - E[Y_t]E[Y_{t+s}]$$

Para $s = 0$:

$$\text{Cov}(Y_t, Y_t) = \text{Var}(Y_t)$$

Para $s = 1$:

$$\text{Cov}(Y_t, Y_{t+1}) = \frac{5}{32}\sigma^2$$

Para $s = 2$:

$$\text{Cov}(Y_t, Y_{t+2}) = \frac{1}{16}\sigma^2$$

Para $s \geq 3$:

$$\text{Cov}(Y_t, Y_{t+s}) = 0$$

O processo é estacionário.

0.5 Questão 5

Use um programa computacional para calcular:

```
# baixando dados

data1 <- read_csv("data/ENERGIA.csv")

data2 <- read_csv("data/OZONIO.csv")

# tratando dados

data1 <- data1 %>%
  mutate(
    Ano = as.numeric(as.character(Ano)),
    Mes = as.numeric(as.character(Mes)),
    date = as.Date(paste(Ano, Mes, "01", sep = "-"), format = "%Y-%m-%d"),
    energia = Energia
  ) %>%
  select(date, energia)

data2 <- data2 %>%
  mutate(
    Ano = as.numeric(as.character(Ano)),
    Mes = as.numeric(as.character(Mes)),
    date = as.Date(paste(Ano, Mes, "01", sep = "-"), format = "%Y-%m-%d"),
    ozonio = Ozonio
  ) %>%
  select(date, ozonio)

# transformando em formato time-series

data1_ts <- ts(data1$energia, start = c(1968, 1), frequency = 12)

data2_ts <- ts(data2$ozonio, start = c(1956, 1), frequency = 12)
```

- média amostral

```
media_amostral1 <- mean(data1$energia)
```

```
media_amostral2 <- mean(data2$ozonio)
```

```
media_amostral1
```

```
[1] 66020.52
```


```
media_amostral2
```

```
[1] 46.89444
```

- C_k e r_k para $k = 1, \dots, 36$.

```
# calculando a autocorrelação (ACF) para K = 1, ..., 36
```


```
acf1 <- acf(data1_ts, lag.max = 36, plot = TRUE)$acf[-1] # remove o lag 0
```



```
acf1
```

```
[1] 0.9514160 0.9174419 0.8840017 0.8483770 0.8154543 0.7804471 0.7185768  
[8] 0.6834363 0.6528914 0.6214676 0.5895272 0.5543717 0.5225446 0.4908249  
[15] 0.4682221 0.4459799 0.4211280 0.3974041 0.3801805 0.3612299 0.3494211  
[22] 0.3342753 0.3146517 0.2967974 0.2838737 0.2703261 0.2597187 0.2483536  
[29] 0.2371584 0.2239555 0.2157054 0.2045383 0.1949174 0.1838837 0.1742343  
[36] 0.1654774
```

```
acf2 <- acf(data2_ts, lag.max = 36, plot = TRUE)$acf[-1]
```



```
acf2
```

```
[1] 0.457739053 0.165169955 -0.025204957 -0.267903375 -0.386381327  
[6] -0.395016694 -0.392795163 -0.291885862 -0.071538185 0.215495164
```

```
[11]  0.355054343  0.426085941  0.364615242  0.178311373 -0.039130730
[16] -0.232983672 -0.300129749 -0.383149164 -0.368928301 -0.173292411
[21]  0.009378308  0.189056564  0.305343616  0.432648385  0.274358601
[26]  0.192129752  0.026931755 -0.263676474 -0.391256416 -0.376087161
[31] -0.334783444 -0.181118099  0.026688826  0.236411592  0.330787234
[36]  0.396128713
```

```
# calculando a variância da série
```

```
var1 <- var(data1_ts)
```

```
var2 <- var(data2_ts)
```

```
var1;var2
```

```
[1] 2915802343
```

```
[1] 539.0223
```

```
# calculando a autocovariância
```

```
autocov1 <- acf1 * var1
```

```
autocov2 <- acf2 * var2
```

```
autocov1
```

```
[1] 2774141108 2675079164 2577574088 2473699718 2377703470 2275629450
[7] 2095227879 1992765203 1903702323 1812076624 1718944670 1616438264
[13] 1523636753 1431148457 1365243012 1300389134 1227925872 1158751931
[19] 1108531136 1053274934 1018842942 974680667 917462113 865402597
[25] 827719475 788217584 757288446 724150126 691507011 653009891
[31] 628954284 596393368 568340648 536168404 508032881 482499493
```

```
autocov2
```

```
[1] 246.731564 89.030291 -13.586034 -144.405898 -208.268157 -212.922813
[7] -211.725358 -157.332993 -38.560678 116.156702 191.382214 229.669830
[13] 196.535752 96.113809 -21.092337 -125.583398 -161.776632 -206.525950
```

```
[19] -198.860587 -93.408476 5.055117 101.905707 164.587023 233.207134
[25] 147.885408 103.562224 14.516817 -142.127503 -210.895939 -202.719372
[31] -180.455747 -97.626697 14.385873 127.431124 178.301701 213.522216
```

- Faça os gráficos da série e de r_k . Comente sobre a presença de tendencia, sazonalidades, ciclos.


```
# gráficos da série, sazonalidade e tendencia

decompose_graph1 <- decompose(data1_ts)

decompose_graph2 <- decompose(data2_ts)


plot(decompose_graph1)
```

Decomposition of additive time series



```
plot(decompose_graph2)
```

Decomposition of additive time series



O primeiro gráfico apresenta uma série temporal com uma tendência aparentemente crescente, com um pico acentuado próximo ao final do período, acompanhado por uma variabilidade aleatória mais intensa. Já o segundo gráfico reflete uma série mais estacionária, com a tendência oscilando suavemente ao longo do tempo, sem padrões de crescimento ou declínio definidos. Em ambas as séries, a sazonalidade se mostra regular e consistente. A principal diferença está no comportamento geral: enquanto a primeira série evidencia um crescimento acentuado e eventos fora do padrão, a segunda mantém estabilidade e equilíbrio entre os componentes.

0.6 Questão 6

Use um programa computacional e a série dos log retornos mensais do IBOVESPA para calcular:

```
data <- tq_get(  
  "^BVSP",  
  from = "1994-07-04",
```

```

to = "2010-08-19",
get = "stock.prices")

data <- data %>%
  select(-symbol) %>%
  mutate(date = as.Date(date, format = "%Y-%m-%d"),
         log_return = log(adjusted / lag(adjusted)))

data <- data %>%
  mutate(month = format(date, "%Y-%m")) %>%
  group_by(month) %>%
  summarise(
    log_return_mes = sum(log_return, na.rm = TRUE)
  )

```

- média e variância amostrais, coeficientes de assimetria e curtose, máximo e mínimo, histogramas;

```

stats_data <- data %>%
  summarise(
    media = mean(log_return_mes, na.rm = TRUE),
    variancia = var(log_return_mes, na.rm = TRUE),
    assimetria = skewness(log_return_mes, na.rm = TRUE),
    curtose = kurtosis(log_return_mes, na.rm = TRUE),
    max = max(log_return_mes, na.rm = TRUE),
    min = min(log_return_mes, na.rm = TRUE)
  )

kable(stats_data,
      caption = "Estatísticas descritivas do Log Retorno mensal do IBOVESPA",
      align = "c") %>%
kable_styling(bootstrap_options = c("striped"), full_width = FALSE)

```

Table 3: Estatísticas descritivas do Log Retorno mensal do IBOVESPA

media	variancia	assimetria	curtose	max	min
0.0140989	0.0086741	-1.231667	4.574243	0.2378635	-0.5034126

```


ggplot(data, aes(x = log_return_mes)) +
  geom_histogram(bins = 30, fill = "blue", color = "black", alpha = 0.7) +

```



```
labs(title = "Histograma da série temporal de IBOVESPA",  
      x = "Preço Ajustado",  
      y = "Frequência")
```


Histograma da série temporal de IBOVESPA



- autocorreções amostrais

```
acf <- acf(data$log_return_mes, plot = TRUE)
```

Series data\$log_return_mes



acf

Autocorrelations of series 'data\$log_return_mes', by lag

0	1	2	3	4	5	6	7	8	9	10
1.000	0.036	-0.021	0.025	0.122	-0.112	-0.150	-0.042	-0.003	-0.034	0.068
11	12	13	14	15	16	17	18	19	20	21
0.007	0.069	-0.036	-0.022	-0.176	-0.072	-0.056	-0.098	-0.080	0.032	0.050
22										
0.083										