

# Prova 2

Beatriz Lima Silveira

## Questão 1

```
# bibliotecas
library(readxl)
library(forecast)
library(rugarch)

# Carregando os dados
Petrobras <- read_excel("Petrobras.xls")

# Calculando o log retorno
log_retornos <- diff(log(Petrobras$PETROBRAS))
```

Ajustando um modelo ARMA.

```
lista_modelos <- NULL

for (d in 0:1){
  for (p in 0:5){
    for (q in 0:5){
      modelo <- forecast::Arima(log_retornos, order = c(p, d, q))
      lista_modelos <- rbind(lista_modelos, c(p, d, q, modelo$aic))
    }
  }
}

lista_modelos <- as.data.frame(lista_modelos)
colnames(lista_modelos) <- c("p", "d", "q", "aic")

modelos <- lista_modelos |>
  dplyr::arrange(aic)
```

```
## Escolhendo o modelo com menor AIC

melhor_ARMA <- forecast::Arima(log_retornos,
                              order = c(modelos[1,]$p,
                                         modelos[1,]$d,
                                         modelos[1,]$q)
                              )

melhor_ARMA
```

Series: log\_retornos  
ARIMA(5,0,4) with non-zero mean

Coefficients:

	ar1	ar2	ar3	ar4	ar5	ma1	ma2	ma3	ma4
	0.6215	-0.0799	0.4473	-0.9721	0.0908	-0.5199	0.0098	-0.4765	0.956
s.e.	0.0446	0.0695	0.0527	0.0334	0.0274	0.0360	0.0537	0.0349	0.021
mean									
	0.0011								
s.e.	0.0010								

sigma^2 = 0.001161: log likelihood = 2941.14  
AIC=-5860.28 AICc=-5860.11 BIC=-5801.85

```
## Utilizando a função auto.arima para comparação

melhor_arma <- forecast::auto.arima(log_retornos)

melhor_arma
```

Series: log\_retornos  
ARIMA(2,0,1) with non-zero mean

Coefficients:

	ar1	ar2	ma1	mean
	0.7943	-0.1287	-0.6811	0.0011
s.e.	0.1147	0.0261	0.1134	0.0008

sigma^2 = 0.001174: log likelihood = 2929.88  
AIC=-5849.76 AICc=-5849.72 BIC=-5823.2

O modelo ajustado usando a função `forecast::arima` indica a presença de 5 parâmetros autoregressivos (AR) e 4 médias móveis (MA). Além disso, o valor muito próximo de zero para a média do modelo sugere que não há um viés significativo na série. A próxima etapa para uma análise mais robusta é avaliar os resíduos e aplicar testes para verificação de ruídos brancos.

Para fins de comparação, foi ajustado o modelo também utilizando `forecast::auto.arima()`. Nesse caso o modelo indicado foi o ARMA(2,1), um modelo menos robusto que performa melhor nas métricas de comparação como AIC.


Por esses motivos, seleciono o modelo ARMA(2,1)

## Questão 02

```
residuos <- (melhor_arma$residuals)
```


```
## ACF e PACF
```

```
acf(residuos)
```



```
pacf(residuos)
```

## Series residuos



```
## Teste de Ljung-Box
```

```
Box.test(resíduos^2, type = "Ljung-Box", lag = 5)
```

Box-Ljung test

```
data: resíduos^2  
X-squared = 515.55, df = 5, p-value < 2.2e-16
```

Rejeita-se a hipótese nula, ou seja, há variância temporal ao longo da série.

```
r_values <- 0:6  
s_values <- 0:0  
best_aic_garch <- Inf  
best_garch_model <- NULL
```

```
for (r in r_values) {  
  for (s in s_values) {  
    spec <- ugarchspec(  

```

```

    variance.model = list(garchOrder = c(r, s)),
    mean.model = list(armaOrder = c(0, 0)),
    distribution.model = "norm"
  )
  possible_model <- tryCatch(
    {
      fit <- ugarchfit(spec, residuos)
      list(model = fit, aic = infocriteria(fit)[1])
    },
    error = function(e) NULL
  )
  if (!is.null(possible_model) && possible_model$aic < best_aic_garch) {
    best_aic_garch <- possible_model$aic
    best_garch_model <- possible_model$model
  }
}
best_garch_model

```

```

*-----*
*           GARCH Model Fit           *
*-----*

```

Conditional Variance Dynamics

```

-----
GARCH Model : sGARCH(5,0)
Mean Model  : ARFIMA(0,0,0)
Distribution : norm

```

Optimal Parameters

```

-----
      Estimate Std. Error t value Pr(>|t|)
mu      0.000298   0.000686  0.43412 0.664199
omega    0.000344   0.000034 10.04551 0.000000
alpha1   0.193470   0.043143  4.48435 0.000007
alpha2   0.202787   0.038826  5.22290 0.000000
alpha3   0.195992   0.042589  4.60194 0.000004
alpha4   0.101606   0.051308  1.98032 0.047667
alpha5   0.038194   0.026228  1.45622 0.145331

```

Robust Standard Errors:

	Estimate	Std. Error	t value	Pr(> t )
mu	0.000298	0.000984	0.30255	0.762235
omega	0.000344	0.000059	5.86386	0.000000
alpha1	0.193470	0.061746	3.13332	0.001728
alpha2	0.202787	0.079380	2.55462	0.010630
alpha3	0.195992	0.059508	3.29357	0.000989
alpha4	0.101606	0.126740	0.80169	0.422734
alpha5	0.038194	0.031720	1.20410	0.228551

LogLikelihood : 3164.514

#### Information Criteria

```
-----
Akaike      -4.2156
Bayes       -4.1908
Shibata     -4.2157
Hannan-Quinn -4.2064
```

#### Weighted Ljung-Box Test on Standardized Residuals

```
-----
                        statistic p-value
Lag[1]                  3.742 0.05305
Lag[2*(p+q)+(p+q)-1] [2] 5.953 0.02265
Lag[4*(p+q)+(p+q)-1] [5] 7.690 0.03517
d.o.f=0
H0 : No serial correlation
```

#### Weighted Ljung-Box Test on Standardized Squared Residuals

```
-----
                        statistic p-value
Lag[1]                  0.1033 0.7479
Lag[2*(p+q)+(p+q)-1] [14] 4.0000 0.8803
Lag[4*(p+q)+(p+q)-1] [24] 8.4435 0.8419
d.o.f=5
```

#### Weighted ARCH LM Tests

```
-----
Statistic Shape Scale P-Value
ARCH Lag[6]      0.2904 0.500 2.000 0.5900
ARCH Lag[8]      0.4765 1.480 1.774 0.9069
ARCH Lag[10]     1.8978 2.424 1.650 0.7900
```

#### Nyblom stability test

-----  
Joint Statistic: 2.6482

Individual Statistics:

mu 1.1297  
omega 0.3325  
alpha1 0.2473  
alpha2 0.1441  
alpha3 0.1687  
alpha4 0.3373  
alpha5 0.2783

Asymptotic Critical Values (10% 5% 1%)

Joint Statistic: 1.69 1.9 2.35

Individual Statistic: 0.35 0.47 0.75

#### Sign Bias Test

-----  
                    t-value    prob sig  
Sign Bias            0.9078 0.36411  
Negative Sign Bias  1.2178 0.22349  
Positive Sign Bias  1.0182 0.30873  
Joint Effect        10.1004 0.01773 \*\*

#### Adjusted Pearson Goodness-of-Fit Test:

-----  
group statistic p-value(g-1)  
1    20      44.30    8.591e-04  
2    30      71.57    1.842e-05  
3    40      81.97    6.883e-05  
4    50      83.04    1.714e-03

Elapsed time : 0.190613

Este modelo é um GARCH(5,0), ou seja, ele modela a volatilidade em cinco passos e não tem termos de média. Assume que os retornos seguem uma distribuição normal.